

# REPORT


---

“ 경사하강법을 이용한 근사함수 ”




과 목 명	지능 시스템
담당교수	조영완 교수님
학 과	컴퓨터공학과
학 번	2016305078
이 름	최영환
제 출 일	2021.04.16

- 다음 그림과 같이 주어진 데이터에 대해 오차를 최소화하는 근사함수(3차 다항함수, 파라미터  $(a, b, c, d)$ )를 경사하강법으로 구하는 예제를 프로그램을 작성하여 실습하고 결과를 정리하여(학습의 중간 과정 포함, 예를 들어, 10 epoch 학습 결과, 100 epoch 학습 결과 등등) 보고서 형태로 제출한다.
- 데이터 쌍  $(x_i, y_i)$ 은 300개를 다음과 같이 생성하여 사용한다.
- $[0, 3]$  구간의  $x_i$ 를 랜덤하게 발생시켜  $y = x^3 - 4.5x^2 + 6x + 2$ 의 함수에 대입하여  $y$ 를 구하고 여기에  $[-0.5, 0.5]$  사이의 값을 랜덤하게 생성하여 더한 값을  $y_i$ 로 한다. (4월 16일까지 Google Classroom 제출)



$(x_i, y_i)$  for  $i = 1, 2, \dots, N$



$y = ax^3 + bx^2 + cx + d$

- 경사 하강법 함수의 구현은 아래 코드를 참고하여 구현하였음.

## 매개변수 학습의 개념 - 예제 구현 코드

```
def linear_regression(X, y, m_current=0, b_current=0, epochs=1000,
learning_rate=0.0001):
    N = float(len(y))
    for i in range(epochs):
        y_current = (m_current * X) + b_current
        cost = sum([data**2 for data in (y-y_current)]) / (2*N)
        m_gradient = -(1/N) * sum(X * (y - y_current))
        b_gradient = -(1/N) * sum(y - y_current)
        m_current = m_current - (learning_rate * m_gradient)
        b_current = b_current - (learning_rate * b_gradient)
    return m_current, b_current, cost
```

< 문제의 조건에 맞는 데이터 쌍 x, y 생성 >

```
# 문제의 조건에 맞는 랜덤한 데이터 생성
def initializing(num_of_data = 300):
    X = []
    Y = []

    for i in range(num_of_data):
        # x 는 [0, 3] 구간의 랜덤한 실수
        x = random.uniform(0, 3)

        # y = x^3 - 4.5x^2 + 6x + 2 의 함수에 랜덤한 실수 x 값 대입 후
        # [-0.5, 0.5] 사이의 값을 랜덤하게 생성하여 더함
        y = x**3 - (4.5 * x**2) + (6 * x) + 2 + random.uniform(-0.5, 0.5)
        X.append(x)
        Y.append(y)

    return X, Y
```

- ▶ 문제의 조건에 맞게 총 300개의 x와 y 값을 생성하는 함수.
- ▶ random.uniform() 함수를 사용하여 [0, 3] 구간의 임의의 실수를 생성하고, 이를 x의 값으로 설정하였음.
- ▶  $y = x^3 - 4.5x^2 + 6x + 2$  에 x의 값을 대입하여 구한 값에 [-0.5, 0.5] 구간의 임의의 실수를 더하여 y의 값으로 설정하였음.
- ▶ x와 y의 값은 총 300개로, 이들 값을 리스트 X와 Y에 넣어서 사용하였음.

< 생성 결과 >

```
1: 0.6337919537437542, 3.8830275443063837 286: 2.7249953774832054, 5.403646745124464
2: 0.2251884392372151, 2.677377470188543 287: 2.0423649657708234, 4.27496092862718
3: 0.24114522550189788, 2.7600603539717845 288: 2.1425772477778526, 3.907009177422373
4: 2.5413749742844085, 4.480060358596582 289: 0.11758531739945832, 2.8160156356833785
5: 2.822480603058248, 5.4757479436586625 290: 1.0465706402815491, 4.040730023756033
6: 0.7360800061389438, 4.335225647817131 291: 2.5064449088847676, 4.954904305003511
7: 2.7505530713557653, 5.2144740302671 292: 0.19757945522483045, 3.33188859261083
8: 1.9671229627812516, 3.564151733193983 293: 0.9379082460157036, 4.073471800362855
9: 0.9351873008289305, 4.512330015500485 294: 0.27815797492033645, 2.98880702622753
10: 0.12627905133228923, 2.779364542689903 295: 0.6286409626585139, 3.812113908832612
11: 0.9303939714827091, 4.41203584017899 296: 0.6368599908618403, 4.660553407001003
12: 0.5548793420548287, 3.9689937650519704 297: 2.784852742073384, 5.7729766141124985
13: 2.4007419204339024, 4.320903722895641 298: 1.891266346713851, 3.710627964971295
14: 1.6964346500746925, 4.511165562599788 299: 1.144872428404593, 4.16650573324087
15: 1.8811501781565438, 3.6051151412134734 300: 1.558928542319029, 4.005805718148021
```

- ▶ 각 번호에서 좌측이 x의 값이며, 우측이 y의 값임.
- ▶ 문제에서 요구된 범위 내에서 x의 값이 생성되었음을 확인하였음.
- ▶ 출력문의 길이가 길어, 일부를 제외하고는 생략하였음.

### < 경사 하강법 함수 line\_regression 함수 구현 >

```
# y = ax^3 + bx^2 + cx + d
# 데이터 개수 300개, 에포크 1000번, learning_rate 는 학습률(스텝사이즈)
def linear_regression(X, Y, num_of_data = 300, epochs = 1000, learning_rate = 0.0001):
    a_current = 0      # 매개변수 a 의 현재값
    b_current = 0      # 매개변수 b 의 현재값
    c_current = 0      # 매개변수 c 의 현재값
    d_current = 0      # 매개변수 d 의 현재값

    # 데이터 개수 300개
    N = num_of_data
    for cnt in range(epochs):
        cost = 0        # 비용함수(cost function) J 값(평균제곱오차), 최소화 하는 것이 목적
        a_gradient = 0  # 매개변수 a 편미분 값
        b_gradient = 0  # 매개변수 b 편미분 값
        c_gradient = 0  # 매개변수 c 편미분 값
        d_gradient = 0  # 매개변수 d 편미분 값
        y_current = []  # i번째 x일 때 예측값 y_current = ax^3 + bx^2 + cx + d
        for i in range(N):
            # i번째 x일 때 예측값 y_current = ax^3 + bx^2 + cx + d
            y_current.append((a_current * X[i] ** 3) + (b_current * X[i] ** 2) + (c_current * X[i]) + d_current)

            a_gradient += (X[i] ** 3) * (Y[i] - y_current[i])  # a 편미분 1단계
            b_gradient += (X[i] ** 2) * (Y[i] - y_current[i])  # b 편미분 1단계
            c_gradient += X[i] * (Y[i] - y_current[i])         # c 편미분 1단계
            d_gradient += Y[i] - y_current[i]                 # d 편미분 1단계
            cost += (Y[i] - y_current[i]) ** 2  # 비용함수(cost function) J 값(평균제곱오차), 최소화 하는 것이 목적

        cost /= (2 * float(N))  # 비용함수(cost function) J 값(평균제곱오차), 최소화 하는 것이 목적
        a_gradient = -(1 / float(N)) * a_gradient  # a 편미분 2단계
        b_gradient = -(1 / float(N)) * b_gradient  # b 편미분 2단계
        c_gradient = -(1 / float(N)) * c_gradient  # c 편미분 2단계
        d_gradient = -(1 / float(N)) * d_gradient  # d 편미분 2단계

        a_current = a_current - (learning_rate * a_gradient)  # a 값, 학습률에 따라 경사하강법
        b_current = b_current - (learning_rate * b_gradient)  # b 값, 학습률에 따라 경사하강법
        c_current = c_current - (learning_rate * c_gradient)  # c 값, 학습률에 따라 경사하강법
        d_current = d_current - (learning_rate * d_gradient)  # d 값, 학습률에 따라 경사하강법

    return a_current, b_current, c_current, d_current, cost
```

- ▶ ppt의 예제 구현 코드를 참고하였음. 예제 코드는 매개변수가 2개인, 1차 다항함수인 경우의 경사 하강법 적용이므로, 이를 매개변수가 4개인 3차 다항함수에 맞춰 수정하였음.
- ▶  $y_{\text{current}}$  는  $y = ax^3 + bx^2 + cx + d$  식을 적용하여 계산된 각 데이터 별  $y$ 의 예측값임.
- ▶ 각 매개변수의 편미분 식
 

$a_{\text{gradient}} = x^3 * (y \text{ 실제값} - y \text{ 예측값})$ 
 $b_{\text{gradient}} = x^2 * (y \text{ 실제값} - y \text{ 예측값})$

$c_{\text{gradient}} = x * (y \text{ 실제값} - y \text{ 예측값})$ 
 $d_{\text{gradient}} = (y \text{ 실제값} - y \text{ 예측값})$

위 계산 과정을 N(데이터의 개수)회 진행한 뒤, 각 값에 1/N을 곱하였음.  
 여기서  $(y \text{ 실제값} - y \text{ 예측값})$ 은 오차를 뜻함.  
 자기 자신의 값에서 자기 자신과 학습률(0.0001)을 곱한 값을 빼주었음.  
 각 매개변수에 대해  $a_{\text{current}} = a_{\text{current}} - (\text{learning\_rate} * a_{\text{gradient}})$  처럼 계산하였음.
- ▶ 비용함수(cost function)는 변수 cost로 설정하였음.  
 cost의 값에 오차의 제곱  $((y \text{ 실제값} - y \text{ 예측값})^2)$ 을 N회 만큼 더한 뒤, 2/N을 곱하였음.
- ▶ 매개변수 a, b, c, d와 비용함수 cost의 값을 반환함.



```
# 에포크 10 마다 근사함수 값 출력
if (cnt+1) % 10 == 0:
    print(f'===== Epoch : {cnt+1} =====')
    print(f'y = {a_current:.4f}x^3 + {b_current:.4f}x^2 + {c_current:.4f}x + {d_current:.4f}')
    print(f'cost = {cost}')
```

▶ 추가로, 에포크 10마다의 변화 관측을 위해 출력문을 함수 마지막 부분에 추가하였음.

### < 결과 확인 >

```
num_of_data = 300
X, Y = initializing(num_of_data)

# 생성한 데이터 출력 (실제값)
for i in range(len(X)):
    print(f'{i+1}: {X[i]}, {Y[i]}')
print("===== End of Initializing =====")
print()
print()

# 경사하강법 시행
a, b, c, d, cost = linear_regression(X, Y, num_of_data=num_of_data, epochs=1000, learning_rate=0.0001)

# 생성한 데이터 그래프 출력
plt.subplot(1, 3, 1)
plt.title("Data")
plt.plot(X, Y, 'r.')

# 근사함수 그래프 출력
plt.subplot(1, 3, 2)
plt.title("Graph of Function Approximation")
# x_range = np.linspace(0, 3, 300)
x_range = np.array(X)
y_range = np.array([a*x**3 + b*x**2 + c*x + d for x in x_range])
plt.plot(x_range, y_range, 'b')

# 생성한 데이터 그래프와 근사함수 그래프 동시 출력
plt.subplot(1, 3, 3)
plt.title("Graph of Data & Function Approximation")
plt.plot(X, Y, 'r.', label='Data')
plt.plot(x_range, y_range, 'b', label='Function Approximation')
plt.legend()
|
plt.show()
```

- ▶ num\_of\_data는 데이터의 개수이므로, 300으로 초기화 하였음.
- ▶ X 와 Y는 각각 x와 y의 실제값으로, initializing 함수를 사용하여 초기화함.
- ▶ 생성된 데이터의 각 값을 모두 출력해준 뒤, 경사 하강법을 시행하여 매개변수들의 값과 비용함수의 값을 구함. (linear\_regression 함수 사용)
- ▶ 그 다음, 생성된 데이터의 그래프와 근사함수의 그래프를 출력하여 결과를 확인하였음.
- ▶ 에포크가 1000인 경우, 10000인 경우를 관측해보았음.

### < 에포크 1000인 경우의 결과 관측 >

```


===== Epoch : 10 =====
y = 0.0294x^3 + 0.0131x^2 + 0.0065x + 0.0041
cost = 8.310497801776194
===== Epoch : 20 =====
y = 0.0556x^3 + 0.0248x^2 + 0.0125x + 0.0080
cost = 7.421703198712656
===== Epoch : 30 =====
y = 0.0788x^3 + 0.0354x^2 + 0.0180x + 0.0117
cost = 6.713859656752421
===== Epoch : 40 =====
y = 0.0994x^3 + 0.0450x^2 + 0.0230x + 0.0152
cost = 6.149770212574142
===== Epoch : 50 =====
y = 0.1177x^3 + 0.0536x^2 + 0.0277x + 0.0186
cost = 5.699885145663554

===== Epoch : 960 =====
y = 0.2025x^3 + 0.2101x^2 + 0.1919x + 0.2046
cost = 3.289877187204555
===== Epoch : 970 =====
y = 0.2018x^3 + 0.2110x^2 + 0.1933x + 0.2064
cost = 3.282982882159778
===== Epoch : 980 =====
y = 0.2011x^3 + 0.2120x^2 + 0.1947x + 0.2082
cost = 3.276105724125696
===== Epoch : 990 =====
y = 0.2003x^3 + 0.2130x^2 + 0.1962x + 0.2101
cost = 3.2692456698430035
===== Epoch : 1000 =====
y = 0.1996x^3 + 0.2139x^2 + 0.1976x + 0.2119
cost = 3.2624026761640863

```

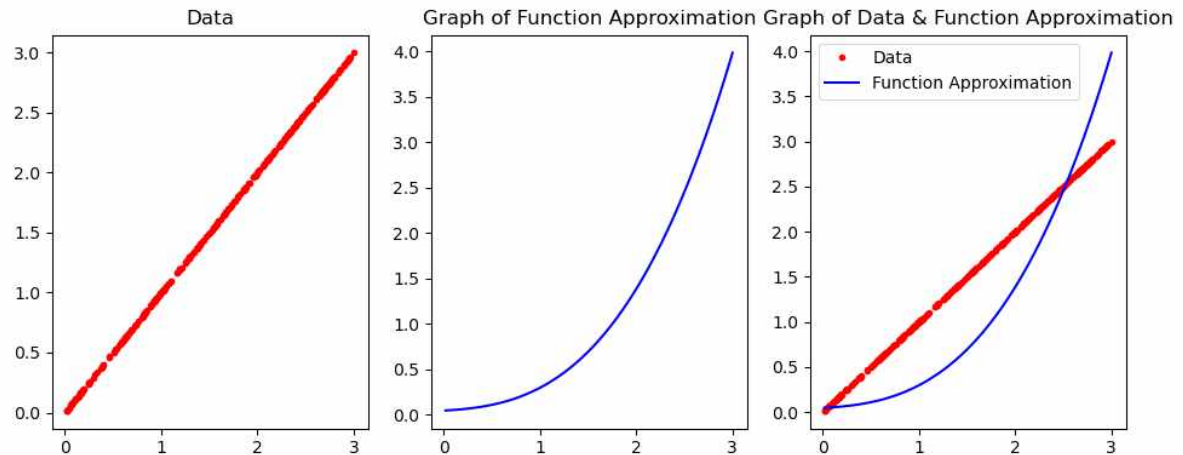
- ▶ 에포크가 1000인 경우의 결과.
- ▶ 에포크가 거듭될수록, 매개변수들의 값과 비용함수 cost의 값이 변화함을 관측하였음.  
출력문이 길어 일부를 제외하고는 생략하였음.
- ▶ 에포크 10마다의 출력을 관측하였으며, 초기 cost의 값은 8을 넘는 값이었으나,  
에포크가 1000에 가까워지면서 3에 수렴하는 것을 확인하였음.

### < 에포크 1000인 경우의 그래프 >



- ▶ 실제 데이터의 그래프(좌), 근사함수의 그래프(중), 데이터와 근사함수의 그래프(우)  
두 그래프의 차이가 큰 것 같아, 초기화 단계에서 실제 데이터를 오름차순으로 정렬한 뒤의  
결과를 관측해보기로 하였음.
- ▶ 근사함수의 그래프의 값은 오름차순으로 정렬된 값이기 때문으로 생각하여, x의 값을  
오름차순으로 정렬한 뒤 해보기로 하였음.

< 에포크 1000인 경우의 그래프(정렬 후) >



- ▶ 여전히 두 그래프의 차이가 있으나, 이전과 비교했을 때, 개선되었음을 확인.  
(y축의 최댓값이 8 이상이었으나, 정렬 이후에는 5 미만.)
- ▶ 이후의 결과들은 모두 데이터가 오름차순으로 정렬되어있는 상태의 결과들임.

< 에포크 10000인 경우의 결과 관측(정렬 전) >

```

===== Epoch : 9950 =====
y = -0.1444x^3 + 0.6089x^2 + 0.8952x + 1.2740
cost = 0.8139209325141684
===== Epoch : 9960 =====
y = -0.1446x^3 + 0.6091x^2 + 0.8956x + 1.2748
cost = 0.8131061433350694
===== Epoch : 9970 =====
y = -0.1448x^3 + 0.6093x^2 + 0.8960x + 1.2756
cost = 0.8122930886914441
===== Epoch : 9980 =====
y = -0.1450x^3 + 0.6095x^2 + 0.8964x + 1.2763
cost = 0.8114817644954758
===== Epoch : 9990 =====
y = -0.1452x^3 + 0.6096x^2 + 0.8969x + 1.2771
cost = 0.8106721666691026
===== Epoch : 10000 =====
y = -0.1453x^3 + 0.6098x^2 + 0.8973x + 1.2778
cost = 0.8098642911440002
    
```

- ▶ 예상한 것과 같이 에포크가 증가할수록, cost의 값이 매우 작아졌음을 확인하였음.

< 에포크 10000인 경우의 결과 관측(정렬 후) >


```

===== Epoch : 9960 =====
y = 0.0133x^3 + 0.2332x^2 + 0.2469x + 0.2232
cost = 0.024690531355583946
===== Epoch : 9970 =====
y = 0.0133x^3 + 0.2333x^2 + 0.2470x + 0.2233
cost = 0.02464675894684951
===== Epoch : 9980 =====
y = 0.0132x^3 + 0.2334x^2 + 0.2471x + 0.2234
cost = 0.024603081889012005
===== Epoch : 9990 =====
y = 0.0131x^3 + 0.2335x^2 + 0.2472x + 0.2235
cost = 0.024559499970072608
===== Epoch : 10000 =====
y = 0.0131x^3 + 0.2336x^2 + 0.2474x + 0.2236
cost = 0.02451601297850503

===== Epoch : 1000 =====
y = 0.1161x^3 + 0.0806x^2 + 0.0563x + 0.0442
cost = 0.14799951781106532
    
```

- ▶ 정렬 이후, cost의 값이 이전과 비교했을 때, 굉장히 많이 줄어들었음을 확인하였음.
- ▶ 에포크 1000에서의 결과도 확인해보았더니, 이전 값과 굉장히 크게 다를름을 확인하였음.
- ▶ 정렬을 한 것이 cost의 결과를 크게 바꾼 것으로 예상됨.

< 에포크 10000인 경우의 그래프 >



- ▶ 실제 데이터의 그래프와의 오차가 크게 줄어들었음을 확인하였음.  
(y축의 최댓값이 4 미만 3.5 이상임을 확인.)

< 결론 >

에포크가 거듭함에 따라, 그리고 비용함수의 값이 감소함에 따라, 오차 (데이터의 실제 값과 근사함수를 통한 예측값의 차이) 가 줄어들었음을 확인하였음.